

Paper A 研究方案：多模型协作的性能来源与成本—性能边界

版本：v0.4（动态执行规划稿）

日期：2026-07-16

状态：未预注册；关键研究决策已确认，D8/D9 数值与 D12 发布矩阵按 Stage 0/G2 流程完成

主要实验实现：MMD main 与 litellm-integration；正式实验须固定 commit SHA

0. 如何审阅这份文档

本方案使用三类标记：

- D#**：研究决策；确认状态、owner 与 gate 见第 20 节；
- G#**：进入下一阶段前必须满足的质量门槛；
- H#**：预注册的研究假设。

建议按以下顺序审阅：

- 先确认第 2–4 节的论文问题、主张边界和主假设；
- 再确认第 7–10 节的任务、模型池和实验条件；
- 然后确认第 11–15 节的指标、统计与有效性控制；
- 最后根据第 17–20 节确定工作量、动态责任配置、预算和待办。

任何 **D#** 改动都应同步更新实验 manifest 和版本号；预注册之后不得覆盖旧版本。

1. 一页式摘要

1.1 研究问题

本研究关注多模型协作系统中性能变化的来源及其适用条件。核心问题是：

多模型协作相对于单模型推理所产生的性能变化，分别有多少来自额外采样、模型间的有效多样性、答案聚合、模型间交互以及协调模型？这些机制在什么任务和运行条件下能够纠正错误，又在什么条件下导致从众、遗漏、错误传播或不必要的成本？

在此基础上，本研究进一步检验：

在控制成员模型能力、模型调用数量、计算预算或真实美元成本后，异构模型组合和结构化审议是否仍能产生超越同模型多采样、简单投票及单模型综合的增量价值？

研究将 MMD 作为主要实验载体，因为其分阶段协议和结构化 trace 允许观察、干预并消融多模型协作过程。研究结论原则上针对所检验的协作机制和实验条件，而不预设 MMD 本身优于其他框架，也不将单一框架上的结果直接推广至所有多模型系统。

1.2 研究对象

研究对象不是 MMD 框架本身，也不是某一组“当前最强模型”的 leaderboard，而是以下多模型协作机制：

1. **Sampling effect**: 同一模型多次生成产生的随机多样性；
2. **Model diversity effect**: 不同模型错误模式的互补性；
3. **Aggregation effect**: 投票或单模型 synthesis 的增益；
4. **Deliberation effect**: critique/revise 是否产生超越 aggregation 的增量；
5. **Coordinator effect**: normalize/compose 模型的能力与偏差；
6. **Task interaction**: 上述机制是否随 reasoning、knowledge、instruction-following 和开放研究任务变化。

1.3 最小可发表贡献

即使结构化多模型审议没有取得最高平均准确率，本研究仍应交付：

- 一项对多模型协作性能来源及其任务依赖性的实证分解；
- 一个成本、质量、延迟匹配的 multi-model deliberation benchmark harness；
- 一组区分 sampling、diversity、aggregation 与 deliberation 的预注册对照；
- wrong→correct、correct→wrong、候选遗漏和异议保留的过程分析；
- 模型错误相关性和初始分歧对组合收益的预测分析；
- 结构化审议、简单投票和单一 judge synthesis 的 Pareto 前沿。

2. 论文定位

2.1 工作标题

推荐标题：

Where Do Multi-Model Gains Come From? Decomposing Sampling, Diversity, Aggregation, and Deliberation

备选：

- *Beyond More Calls: When Does Heterogeneous Multi-Model Deliberation Beat Sampling and Voting?*
- *The Cost of Deliberation: Decomposing Diversity, Voting, and Revision in Multi-LLM Systems*
- *Do Models Need to Talk? A Cost-Matched Study of Heterogeneous LLM Deliberation*

D1 – 标题与主叙事（已确认）

Paper A 将性能来源分解作为总问题，把有效多样性和结构化审议的增量价值作为两个主要确认方向。

2.2 文献中的位置

研究直接承接四类工作：

- 1. 多模型 selection/fusion：LLM-Blender、Mixture-of-Agents；
- 2. 多模型采样与投票：More Agents Is All You Need、self-consistency；
- 3. 多智能体 debate：Du et al.、Debate or Vote、Voting or Consensus、Demystifying MAD；
- 4. 托管式或产品化 multi-model synthesis 系统。

现有证据存在明确冲突：早期工作报告 debate 提高 reasoning 和 factuality；后续受控研究发现 majority vote 可以解释大量收益，且任务类型、观点多样性与置信度会改变结果。本研究的价值是把多模型协作视为一组可分解机制，并利用 MMD 的阶段 trace 作为观测与消融工具，在现代异构闭源/开放模型上同时研究最终效果和错误转移机制。MMD 是本研究的主要实现，不是待证明优越性的研究对象。

2.3 主张阶梯

论文只应根据结果选择能够被数据支持的层级：

层级	可允许的主张	所需证据
L1 描述性	不同协议形成不同成本—质量前沿	完整、重复、可复现运行
L2 关联性	低错误相关性/高初始分歧预测较大组合收益	跨任务、跨 panel 的 held-out prediction
L3 协议效应	critique/revise 相对 vote-only 产生净纠错	同 panel、同任务、预注册 paired ablation
L4 受限一般化	某机制在特定任务族、预算和模型池中稳定成立	多任务块、独立重复、交互项
禁止	“异构模型普遍优于单模型”或“厂商多样性导致正确性”	本设计无法支持普遍或训练来源因果主张

3. 概念模型：最终增益来自哪里

对任务 (x)、panel (S)、协议 (p)，定义最终质量：

[
$$Q(x,S,p)=Q_{\{base\}}+G_{\{sample\}}+G_{\{diversity\}}+G_{\{aggregation\}}+G_{\{deliberation\}}+G_{\{coordinator\}}+\backslash varepsilon$$

]

这不是拟合时必须采用的线性结构，而是实验设计的分解框架：

- ($G_{\{sample\}}$): 同一模型多次调用即可获得的收益；
- ($G_{\{diversity\}}$): 不同错误通道提供的补充信息；
- ($G_{\{aggregation\}}$): 投票、选择或 synthesis 的收益；
- ($G_{\{deliberation\}}$): 看到他人答案、批评和修订的额外收益；

- (G_{coordinator}): 候选归并和最终写作模型自身带来的变化。

本研究不假设这些项都为正。尤其是：

- critique/revise 可能产生 correct→wrong；
- normalize 可能遗漏正确少数意见；
- coordinator 可能依靠自身能力纠正 panel，也可能重写掉真实分歧；
- 多模型可能因为共同训练数据而形成 false consensus。

4. 研究问题与预注册假设

本节区分三类内容：性能来源的分解问题、可以做确认性检验的假设，以及尚不适合预设方向的探索问题。第 3 节中的各项不是天然可相加或彼此独立的因果成分；每个“来源”只能通过明确的协议对照来估计。除非下文另有说明，所有效应均指同一批 task 上的 paired task-level effect，并同时报告质量、实际成本、延迟和失败率。

4.1 RQ1：多模型协作的性能变化来自哪些步骤？

RQ1： 相对于单模型回答，多模型协作的最终质量变化分别出现在哪些步骤：增加同模型采样、引入异构模型、改变聚合方式、加入显式投票，以及加入 critique/revise？每一步带来的质量变化是否足以补偿其成本、延迟和系统失败风险？

RQ1 通过第 9 节的嵌套对照回答：

待估计增量	主要对照	可以支持的解释	不能单独支持的解释
Sampling increment	C1 – matched Co	同一模型增加独立样本后的净变化	模型多样性或模型交互的作用
Diversity increment	C2 – C1	在能力与成本匹配下，异构成员相对同模型采样的净变化	厂商或训练来源的因果效应
Synthesis increment	C3 – C2	单 coordinator synthesis 相对确定性投票的净变化	coordinator 利用 panel 信息还是独立解题
Explicit-ballot increment	C5 – C4	显式 ballot 阶段在可追溯协议中的净变化	ballot 之外所有协议设计的一般优势
Deliberation increment	C6 – C5	critique/revise 在其余阶段相同条件下的净变化	所有 debate 或多智能体系统的一般效果

RQ1 是分解性研究问题，不预设每个增量为正。为减少随机生成造成的混杂，C2/C3 以及 C4/C5/C6 在协议允许时应复用同一组匿名化 initial proposals，并从共同的上游 artifact 分支运行。无法复用时，必须依赖独立重复并降低因果措辞。

4.2 RQ2：有效多样性是否产生超越同模型采样的增量价值？

RQ2: 在 panel size、成员平均 solo ability、输出上限和预计成本预先匹配后，低错误相关性的异构 panel 是否比同模型多采样或高错误相关性 panel 获得更大的 aggregation gain?

主要估计量是 held-out confirmatory tasks 上的 C2 – C1 paired quality difference；辅助分析比较多个合格 panel 的 screening error correlation 与 held-out panel gain。panel 的选择和相关性计算只能使用 screening split，不能使用 confirmatory 结果。

H1 – 有效多样性的增量假设

在预注册的匹配容差内，P-diverse 的 C2 – C1 task-level 平均质量差高于 P-family/P-homo 的对应差值。统计检验回答效应是否高于零；是否具有实际价值则由团队预先确定的最小有意义质量差 (Δ_Q) 与成本约束共同判断。

解释边界：H1 即使成立，也只支持“以 screening error correlation 定义的有效多样性与增量收益相关，并在所测试 panel 中形成受控差异”；它不支持“跨厂商”本身导致性能提升。若无法找到满足能力与成本匹配的 panel，H1 不进入确认性检验，RQ2 降为带协变量的关联分析。

4.3 RQ3：结构化审议在何时产生净纠错？

RQ3: 在同一 panel、同一 task 和共同 initial proposals 上，加入 critique/revise 后，最终结果相对非交互式 vote-only 聚合发生多少 wrong→correct 与 correct→wrong 转移？这种净变化是否由审议前即可观察的初始分歧所调节？

主要估计量是 C6 – C5 的 paired quality difference、增量成本和增量延迟。鉴于现有文献对平均审议收益的方向并无稳定共识，本研究不预注册“C6 的总体平均质量必然高于 C5”。总体效应以 effect size 和置信区间回答，而不是通过缺乏依据的方向性假设回答。

H2 – 分歧调节假设

审议前的 initial disagreement 越高，C6 – C5 的 task-level quality difference 越大。检验使用预注册的连续分歧指标；若为了展示而划分高/低分歧组，阈值必须由 screening 数据确定，不能根据 confirmatory 结果选择。

H3 – 高分歧任务的净纠错假设

在按 screening 规则预先定义的高分歧任务中，从 C5 错误到 C6 正确的比例高于从 C5 正确到 C6 错误的比例。该假设检验审议是否产生净纠错；它不以输出变长、共识标签变化或更多模型修改答案作为成功标准。

决策解释：即使 H2/H3 成立，结构化审议也只有在质量增益达到 (Δ_Q)，或在预注册的成本—质量规则下进入 Pareto 前沿时，才被判断为具有实际采用价值。

4.4 Secondary RQs：解释机制与边界

以下问题保留为 secondary/exploratory，不在当前版本中强行设置方向性假设：

- **RQ4 – Aggregator/coordinator:** synthesis、normalize 和 compose 的收益有多少来自整合 panel 信息，有多少来自 coordinator 自身直接解题能力？需要 coordinator-only、panel-blind 或角色替换消融后才能回答。
- **RQ5 – 信息保留:** 正确少数意见在 critique、revise、normalize、vote 和 compose 中分别在哪里被保留、合并或丢失？主要观察 candidate recall、dissent survival 和阶段性 correct→wrong 转移。

- **RQ6 — 任务边界：** sampling、diversity、aggregation 和 deliberation 的增量效应是否在预注册的任务块间不同？任务交互只用于限定适用范围，不将事后表现最好的 task 子集改写成主要发现。
- **RQ7 — 可预测性：** 仅使用运行前或审议前可获得的信号，能否在 held-out tasks 上预测结构化审议的收益或伤害？本研究只评估可预测性，不训练生产级自适应 router。

只有在 preregistration 前补齐对应消融、主要结果变量和多重比较归属后，RQ4–RQ7 中的问题才能升级为确认性假设。

4.5 预注册前必须由团队填写的判定项

以下内容未确定前，H1–H3 仍是研究方向，而不是可提交的预注册假设：

1. 最小有意义质量差 (ΔQ)，以及可接受的增量成本或 ICER 规则；
2. panel 平均 solo ability 与预计成本的匹配容差；
3. error correlation 的主定义、screening/confirmatory split 和 panel 选择算法；
4. initial disagreement 的主指标，以及 H3 高分歧任务的预定义规则；
5. C1 对应的 matched Co、主要 coordinator 和 C4/C5/C6 的上游 artifact 复用规则；
6. H1–H3 的主要 task blocks、效应尺度、多重比较 family 和失败计分方式。

5. 研究范围与实验结构

5.1 确认性研究边界

RQ1–RQ3 和 H1–H3 的确认性证据来自同一个受控机制研究：

- tools off，避免搜索策略、来源质量、工具调用次数和检索污染改变待识别机制；
- panel size 固定为 $N=3$ ，模型数效应不与模型异构性或审议效应混合；
- R、K 为 primary task blocks，I 为 secondary；F 和开放研究任务只用于后续边界检查；
- primary outcomes 使用确定性或官方 scorer，Stage 1–3 不依赖 LLM-as-a-judge；
- 同一 confirmatory sampling frame、模型 snapshot、prompt、coordinator 和失败规则贯穿所有主要对照；
- Structural track 估计协议步骤的自然增量，Budget-matched track 检验这些增量是否优于相同预算的替代用法。

D2 – 确认性实验是否 tools off (已确认)

Paper A 的 Stage 1–3 全部 tools off，以避免模型协作效应与检索行为效应混合。该决定不限制后续论文或 Stage 4 外部效度扩展研究 tools-on 场景。

5.2 Stage 0: Screening、pilot 与设计锁定

Stage 0 只用于构建设计，不能产生论文的确认性结论：

1. 在 screening split 上估计各模型的 solo ability、实际成本、失败率和 pairwise error correlation;
2. 根据预先声明的算法生成 P-diverse、P-family/P-homo 及必要的能力—成本匹配候选;
3. 用 pilot 检查 Co—C6 的可运行性、上游 artifact 分支、scorer 和 trace 完整性;
4. 估计 task-level variance, 确定 (δ_Q)、样本量、重复次数和成本上限;
5. 固定 initial disagreement 指标及 H3 的高分歧判定规则;
6. 锁定 confirmatory tasks、panels、coordinator、prompts、主要分析和排除规则。

如果找不到满足预注册能力与成本容差的高/低多样性 panel, H1 在进入 confirmatory 前撤回并记录原因; RQ2 只保留为关联性分析。不得为了保留 H1 而在看过 confirmatory 结果后放宽匹配标准。

5.3 Stage 1: RQ1 性能来源分解

Stage 1 在锁定的 task $\times$ panel $\times$ repetition 单元上运行 Co—C6, 回答各协议步骤在哪里产生收益、损失和额外系统风险。

运行结构分为三条可比较分支:

- **Solo/sampling branch:** matched Co 与 C1, 估计 sampling increment;
- **Heterogeneous aggregation branch:** 生成一组匿名化异构 initial proposals, 并共享给 C2、C3 以及协议允许共享上游输入的后续条件;
- **Traceable protocol branch:** C4/C5 从相同 proposals 与 normalize artifact 分支; C6 从相同 initial proposals 进入 critique/revise, 再继续 normalize、vote 和 compose。

每个分支都保存 task quality、实际成本、wall-clock latency、失败状态和阶段 trace。RQ1 的目标是估计每个预定义 contrast 的效应与不确定性, 不根据结果选择一条“最成功”的路径作为唯一主结果。

5.4 Stage 2: RQ2/H1 有效多样性确认

Stage 2 使用 Stage 0 锁定的 panel 和 held-out confirmatory tasks:

- 分别为 P-diverse 与 P-family 锁定一个成员能力和预计成本匹配的 P-homo reference; 异构 panel 运行 C2, 对应的 P-homo reference 运行 C1;
- 主要检验 H1 规定的 difference-in-differences, 而不只比较两个 panel 的最终分数;
- 使用 screening error correlation 解释 panel 类型, 不用 confirmatory correctness 重新定义“多样”;
- 同时报告 matching balance、oracle coverage 和 unique correct coverage, 区分模型互补性与成员能力差异;
- H1 的确认性结论只适用于通过 matching gate 的 panel。

Stage 1 和 Stage 2 是不同的分析模块, 但可在同一批次中交错运行, 以减少 provider 时间、负载或模型漂移与 condition 重合。

5.5 Stage 3: RQ3/H2—H3 审议净纠错确认

Stage 3 对每个 task × panel × repetition 保存共同 initial proposals，并分支运行 C5 与 C6：

1. 在任何 critique/revise 发生前计算 initial disagreement；
2. 对 C5 与 C6 使用相同的匿名顺序、coordinator、输出上限和下游失败规则；
3. 以 C6 – C5 估计平均质量、成本和延迟增量；
4. 用预注册的连续分歧指标检验 H2；
5. 用预定义高分歧规则和 paired error transition 检验 H3；
6. 分别报告 wrong→correct 与 correct→wrong，不用净值掩盖双向变化。

Stage 3 不以“更多模型修改了答案”或“最终形成共识”作为成功；成功标准必须来自质量变化与预注册的成本—质量判定规则。

5.6 Stage 4：数据锁定后的边界与解释分析

RQ4–RQ7 以及外部效度分析只在主要数据和主分析锁定后启动，可包括：

- coordinator-only、panel-blind、角色替换和顺序敏感性消融；
- candidate recall、dissent survival 和阶段性错误转移的 trace 分析；
- F 或开放研究任务上的小规模复现；
- 与公开论文或可访问外部多模型系统的结果进行同任务、同评分口径的上下文比较。

外部系统比较只回答“本研究结果与现实系统处于什么相对位置”。由于内部 prompt、调用拓扑、模型版本和资源预算通常不可完全对齐，它不参与 H1–H3，也不能用于归因本研究中的具体协议机制。

5.7 为什么不采用模型 × panel × 协议 × 任务的全因子设计

全因子设计既超出预算，也会产生大量没有直接对应 RQ/H 的比较。本研究采用顺序锁定和针对性对照：

1. Stage 0 只选择模型、panel 和阈值；
2. Stage 1–3 只运行回答 RQ1–RQ3 与 H1–H3 所需的条件；
3. Stage 4 只解释已锁定主结果的边界，不回头改变主要假设；
4. 所有未预注册的模型、panel、task 子集和协议组合明确标为 exploratory。

6. 实验单位与数据层级

层级	定义	主要用途
Task	一个 benchmark item	主要统计抽样单元
Run	一个 task × condition × repetition	最终质量、成本、延迟
Inner call	一个 phase × model 调用	usage、错误、retry、阶段成本
Claim	proposer 产生的原始主张	来源、正确性、修订
Candidate	normalize 后的候选主张	candidate recall、合并与遗漏
Ballot	model 对 candidate 的投票	共识、异议与 veto
Panel	一组成员模型及 coordinator	ability、diversity、cost profile

主要推断单位是 task，而不是模型调用。重复调用是同一 task-condition 下的随机重复，不能伪装成独立样本。

7. 任务与数据集设计

7.1 推荐任务块

Block	推荐来源	主要能力	评分方式	在论文中的角色
R: Reasoning	LiveBench reasoning/math、GPQA	多步推理、科学问题	exact/official	Primary
K: Knowledge	MMLU-Pro/GPQA 分层题目	专业知识+推理	exact/official	Primary
I: Instruction	LiveBench instruction-following/data analysis 的可判分子集	格式、约束、分析	official scorer	Primary/secondary
F: Frontier	HLE text-only 分层子集	高难专家知识	official evaluator	Secondary
O: Open Research	DRACO	搜索、综合、引用	rubric multi-judge	External validity

7.2 推荐的首轮范围

- Screening：约 120 个分层 task，用于估计单模型能力、成本和错误相关性；
- Confirmatory：样本量不预先拍定，由 screening/pilot 的 task-level variance 和最小有意义效应做模拟；
- Open Research：先做 10–20 题工程 pilot，再决定是否完整运行 DRACO 100。

120 是工程起点，不是统计功效声明。

D3 – 主任务块（已确认）

R + K 为 primary，I 为 secondary，F/O 只进入 Stage 4。这样可以用确定性 scorer 完成主要机制判断，并把高难任务与开放研究场景限定为外部效度检查。

7.3 数据纳入与排除规则

正式运行前固定：

- dataset release、commit/hash 和 license；
- 题目语言与模态；
- 是否允许检索；
- 图片题是否排除；
- 无效/争议答案清单；
- 答案解析规则；
- provider content filter 的处理；
- 泄漏/污染风险。

不得根据某个系统的表现事后删除题目。发现 benchmark 错题时，必须在盲于 condition 的数据质量流程中决定，并同时报告包含/排除后的敏感性分析。

8. 模型池与 panel 选择

8.1 初始模型池

推荐冻结 6–8 个模型 snapshot：

- 3 个不同家族的 strong/frontier 模型；
- 2–3 个不同家族的 budget/fast 模型；
- 1–2 个 open-weight 或低成本 specialist；
- 至少两个能力相近但家族不同的模型，用于匹配多样性对照。

每个模型必须记录：

- 完整 model id/snapshot；
- provider 与 route；
- 调用日期；
- 支持的 temperature/seed/reasoning 参数；
- 输入/输出价格与额外费用；
- context limit；
- 工具和结构化输出兼容性；
- content-filter/失败行为。

D4 – 具体模型池（已确认冻结规则）

具体 model id、provider route 和 price snapshot 在 Stage 0 screening 开始前冻结。screening 中途若模型不可用，应重跑受影响的 screening 条件并重新执行 panel selection；不得把替代模型直接并入原 screening 数据。具体模型名单根据团队可用 key、稳定性和价格临近 Stage 0 确认，不把论文提前绑定到可能下线的别名。

8.2 Screening 设计

每个模型在同一批约 120 个 task 上独立运行 2 次，得到：

- solo accuracy/score;
- 每题成本和 latency;
- answer distribution;
- pairwise correctness/error correlation;
- 每题置信/格式/拒答行为;
- 失败和不可解析率。

8.3 Panel 类型

从 screening 中选择，不全枚举所有组合：

Panel ID	定义	研究目的
P-top	solo ability 最高的三个模型	强度上限
P-budget	成本较低且达到最低能力门槛的三个模型	低成本前沿
P-diverse	在 ability/cost 约束下错误相关性最低	有效多样性
P-homo	同一模型三次独立实例	sampling 对照
P-family	同家族或高度相关的三个配置	低多样性对照
P-specialist	不同任务 specialist 的组合	专业互补扩展

P-diverse 与 P-family/P-homo 的比较必须尽可能匹配：

- panel size;
- 平均 solo score;
- 预计美元成本;
- 最大输出长度;
- reasoning setting。

如果无法同时匹配，预注册优先级为：panel size → solo ability → cost，并在模型中显式控制剩余差异。

8.4 “有效多样性”的操作化

至少使用四类指标：

1. **Answer disagreement**：初始答案不一致率或标准化熵；
2. **Error correlation**：pairwise correctness/error 的 phi/Pearson correlation；
3. **Oracle coverage**：至少一个成员正确的任务比例；
4. **Unique correct coverage**：只有某成员提供正确答案/正确 claim 的比例。

语义 embedding distance 仅作为补充，因为它可能主要反映文风。

9. 实验条件

9.1 核心条件

C4–C6 使用 MMD 对三类可追溯协作协议进行操作化。论文的机制结论应指向相应的聚合、投票或审议过程；“MMD Quick/Vote/Standard”仅表示本研究中的具体实现。

ID	条件	流程	主要识别对象
Co	Solo	单模型直接回答	个体能力基线
C1	Homo-Sample-Vote	同模型 K=3 独立回答，确定性投票	sampling effect
C2	Hetero-Vote	异构 K=3 独立回答，确定性投票	diversity over sampling
C3	Hetero-Synthesis	异构 K=3，单 coordinator 综合	judge/aggregation effect
C4	Traceable-Quick (MMD Quick)	Propose→Normalize→Compose	traceable aggregation
C5	Traceable-Vote (MMD Vote)	Propose→Normalize→Vote→Compose	explicit ballot effect
C6	Structured-Deliberation (MMD Standard)	Propose→Critique→Revise→Normalize→Vote→Compose	deliberation effect

9.2 Primary contrasts

Contrast	回答的问题
C2 – C1	异构模型是否超过同模型采样？
$\Delta_{\text{diverse}} - \Delta_{\text{family}}$ ，其中 $\Delta = \text{C2} - \text{matched C1}$	低错误相关性是否带来超越一般异构性的额外 aggregation gain？
C3 – C2	单模型 synthesis 是否超过简单投票？
C5 – C4	显式 vote 是否增加价值？
C6 – C5	critique/revise 是否有净增量？
C6 vs best Pareto baseline	结构化审议是否值得其成本？

D5 – Primary confirmatory effects (已确认)
H1 的 diversity difference-in-differences 与 C6–C5 是两个 primary confirmatory effects。单独的

C2–C1 是 RQ1 的分解估计；H1 进一步比较低相关 panel 与匹配高相关 panel 的 aggregation gain。

9.3 条件性角色消融

只在核心结果表明 coordinator 可能影响结论时运行：

- strong vs budget coordinator；
- coordinator in-panel vs out-of-panel；
- normalize 与 compose 使用同/不同模型；
- panel identity 显示 vs 匿名；
- candidate/response order permutation；
- coordinator-only 直接回答。

D6 – 角色消融是否进入主实验（已确认）

coordinator、角色替换、身份显示和顺序等消融不进入主实验；只在主要数据锁定后，根据确认性结果触发相应的 Stage 4 分析。

9.4 外部系统结果对照

外部多模型系统不进入确认性条件 Co–C6。主结果锁定后，可以选择公开方法或可访问系统做上下文比较：

- 尽可能使用相同任务、评分器、模型能力层和检索权限；
- 同时报质量、实际成本、延迟和失败率，不只比较公开总分；
- 分开报告系统自然配置与尽可能匹配的配置；
- 无法核对内部 prompt、调用拓扑或模型版本时，明确标为 naturalistic comparison；
- 不用外部系统结果解释 Co–C6 中某个阶段的因果作用。

D7 – 是否运行外部系统对照（已确认）

外部系统对照是可选 Stage 4，不是 Paper A 完成或投稿的必要条件。只在 Stage 1–3 完成、数据锁定且存在可比任务与预算时进行；否则仅在讨论中与公开结果做限定性比较。

10. 单次运行与随机化流程

10.1 运行前冻结

每个 experiment batch 必须生成不可变 ExperimentManifest：

- experiment id/version；
- git SHA、backend 与 protocol version；
- dataset hash；
- model ids、provider、route；

- panel 和 coordinator;
- prompt version/hash;
- temperature、seed (若支持)、reasoning;
- max tokens、timeout、retry、repair;
- tool config;
- price snapshot;
- scorer/judge version;
- exclusion list。

10.2 随机化

- 对 task 的运行顺序随机化，避免时间/provider load 与 condition 完全重合;
- 在允许时交错运行 conditions，而不是先跑完一种条件;
- panel 回答匿名并随机排列给 coordinator;
- 对 synthesis/judge 做顺序反转敏感性检查;
- 同一 task $\times$ panel $\times$ repetition 内，预注册的嵌套消融可以共享 initial proposals，并从不可变上游 artifact 分支，以减少协议前随机差异;
- 不同 repetition 必须使用独立请求，不得复用上一次 repetition 的 proposals 或最终结果。

10.3 参数纪律

- 主实验使用统一 system/user prompt 意图；协议差异所需 prompt 除外;
- 闭源模型不支持 seed 时，记录为 unsupported，并用独立重复估计随机性;
- 不把 API 中相同的 temperature/reasoning 字段等同于相同内部计算;
- 不为单个模型手工优化 prompt，除非为所有模型采用预注册的兼容模板;
- 结构化输出失败按统一 repair/retry policy，所有额外调用计入成本。

10.4 失败与缺失

主分析采用 intent-to-treat:

- content filter、超时、不可解析、未达 quorum 都计入系统失败;
- 质量评分按预注册的失败分值处理;
- 成本计入失败前已经发生的所有调用;
- 同时报告 per-protocol 结果作为敏感性分析;
- 不用无限重试把失败隐藏掉。

11. 结果指标与操作定义

11.1 Primary outcomes

1. **Task quality**: 官方 exact/scorer 的 task-level correctness 或 normalized score;
2. **Actual cost**: provider 返回或版本化价格表计算的 run-level USD;
3. **Pareto status**: 一个 condition 是否被另一个 condition 在质量和成本上同时支配;
4. **Deliberation marginal value**: C6 相对 C5 的质量增量、成本增量和延迟增量。

11.2 Secondary system outcomes

- input/output/reasoning tokens;
- total wall-clock latency、p50/p95;
- TTFT（仅作为用户体验补充，不与完整审议延迟混淆）;
- success、timeout、content filter、parse failure;
- partial quorum;
- retry/repair 次数;
- unknown pricing 比例。

11.3 过程指标

Initial disagreement

对可规范化为离散答案的任务：

$$[D_{\text{vote}} = 1 - \frac{\max_y n_y}{N}]$$

同时报告标准化熵。开放 claim 使用语义聚类仅作参考。

Oracle coverage

$$[O(S) = \frac{1}{T} \sum_{t=1}^T \mathbb{1}(\exists m \in S: y_{m,t} \text{ correct})]$$

它表示聚合器在不创造新知识时的理论上限。

Net correction

$$[NC = P(\text{wrong} \rightarrow \text{correct}) - P(\text{correct} \rightarrow \text{wrong})]$$

需要分别在 agent revision 层和最终 system 层计算。

Debate gain

$$[G_{\text{debate}} = Q_{\text{standard}} - Q_{\text{pre-debate vote}}]$$

确认性审议增量以共享 initial proposals 后分支运行的 C6 – C5 为准。每个 C6 run 仍应从其 initial proposals 保存 pre-debate majority 作为过程诊断指标，但该 majority 不替代完整的 C5 对照。

Candidate recall

闭集任务：正确答案或支持正确答案的原始 claim 是否进入 normalize candidates。

开放任务：以 task-specific rubric claim 或人工标注的关键 claims 计算；若无法可靠标注，只做案例分析，不给出伪精确总体数字。

Dissent survival

少数但正确/重要的原始 claim 是否经过 revise、normalize、vote 和 compose 保留到最终输出。

11.4 多目标结果

除 Pareto 图外，报告：

$$[ICER = \frac{Q_A - Q_B}{Cost_A - Cost_B}]$$

即每增加一单位质量需要的增量美元成本。若分母接近 0 或条件被支配，不强行解释该比值。

12. 统计分析计划

12.1 分析原则

- task 是主要抽样单元；
- 所有主要比较采用同题 paired design；
- 同一 task 的 repetitions 不视为独立 task；
- 报告 effect size、95% CI 与完整分布，不只报告 p-value；
- 不把跨 benchmark 的原始分数直接平均，先在任务块内标准化或分别报告。

12.2 Primary analysis

对于二元 correctness：

- paired difference 与 cluster bootstrap CI；
- McNemar test 作为简单配对检验；
- 分层 logistic mixed-effects model 检验 protocol × task block、diversity × task difficulty。

对于连续 scorer：

- task-cluster bootstrap；
- mixed-effects/分层回归，task block 与 panel 作为层级；
- 必要时使用稳健或秩方法处理重尾分布。

12.3 Diversity analysis

预测 panel gain:

$$[\text{Gain}_{\{S,t\}} = \beta_0 + \beta_1 \text{Ability}_S + \beta_2 \text{Cost}_S + \beta_3 \text{ErrorCorr}_S + \beta_4 \text{OracleCoverage}_S + \beta_5 \text{TaskDifficulty}_t + u_t + \epsilon]$$

模型家族/跨厂商变量放在错误相关性之后加入，比较其增量解释力。避免将同一 screening 数据既用于选择 panel 又用于无偏评估：panel selection 使用 screening split，最终预测检验使用 held-out confirmatory tasks。

12.4 多重比较

- H1–H3 构成确认性检验 family，使用预注册的 family-wise correction；
- RQ1 的嵌套增量全部报告 effect size 与置信区间，但除非在预注册中明确升级，不将其中每个对照分别作为新的显著性主张；
- secondary contrasts 使用 Holm 或 FDR；
- exploratory process metrics 明确标为探索性；
- 不根据显著性把 secondary 结果改写成 primary。

12.5 样本量与重复次数

Screening/pilot: 每个基础 condition 2 次独立重复，用于估计方差和失败率。

Confirmatory: 主要 conditions 默认至少 3 次，finalist 可增至 5 次，但最终次数由 pilot power simulation 和预算确定。

D8 – 最小有意义效应（决策流程已确认）

WP1 与 WP5 在 Stage 0 pilot 后，根据 task-level variance、评分尺度和实际调用成本提出 (Δ_Q) 与 ICER 判定规则，团队在 G2 批准。不要把“统计显著但实际只有极小提升”视为成功；D8 未批准前不得启动 confirmatory。

13. 成本与延迟分析

13.1 两条比较轨道

Structural track: 同 panel、同任务、统一每次调用上限，允许协议产生不同总调用量；测量每个阶段自然增加的成本与收益。

Budget-matched track: 为每个 task 设置相同的总美元或 token envelope；baseline 可用相同预算增加采样或使用更强单模型。

Structural track 用于解释阶段机制；Budget-matched track 用于回答“用户应该买什么”。

13.2 成本口径

优先级:

- 1. provider 响应返回的实际 cost;
- 2. 固定日期的官方价格 × 实际 usage;
- 3. 无法确定时标为 unknown，不伪造。

每张成本图必须说明是否含：

- retry/repair;
- reasoning tokens;
- search/tool fee;
- failed calls;
- judge/scorer 成本。

评测成本与被评系统推理成本分开报告。

13.3 延迟口径

- total wall-clock 是主指标;
- fan-out 并行阶段同时报告最大单调用 latency;
- 排队/限流可能影响 wall-clock，因此 conditions 交错运行并记录 provider/time;
- 不把串行调用数直接当作延迟估计。

14. 数据质量、有效性与偏差控制

14.1 内部有效性

风险	控制
模型能力与多样性混杂	ability/cost matching、协变量与 held-out tasks
coordinator 过强	synthesis、coordinator-only、role sensitivity
输出长度影响 scorer	记录长度、必要时做长度控制/协变量
顺序/身份偏差	匿名、随机排列、顺序反转
prompt 不等价	prompt versioning、统一意图与模板审查
重试掩盖失败	ITT、固定 retry policy、失败调用计费

14.2 外部有效性

- 模型池不是所有模型的代表;
- 闭源模型可能静默更新;
- benchmark 任务不同于真实长时工作;
- tools-off 主实验不代表联网 agent;
- 英文主实验不能自动外推到中文;
- 开放研究任务和外部产品对照只提供外部效度，不应覆盖闭集机制结果。

14.3 Benchmark 污染

- 固定最新可用 release 与访问日期；
- tools-on 阻断 rubric/answer 域；
- 保存 search query/URL trace；
- 优先使用持续更新、可自动评分任务；
- 不把“Google-proof”视为绝对无污染保证。

14.4 Judge 偏差

Stage 1–3 不依赖 LLM judge。Stage 4 若包含开放任务或必须使用 LLM judge 的外部比较，则必须：

- 至少三个不同家族 judge；
- identity blind；
- position randomization/reversal；
- criterion-level rubric；
- 先做人评 calibration pilot；
- 报告 judge 间一致性和绝对分数敏感性。

14.5 模型漂移

- 保存 snapshot/route 和响应 metadata；
- 同一 confirmatory batch 尽量短时间完成；
- 每日运行固定 anchor tasks；
- anchor score 或响应行为突变时暂停 batch；
- 不把漂移前后数据无说明合并。

15. 研究基础设施要求

15.1 ExperimentManifest

必须支持从一个 manifest 复现完整 batch，并包括第 10.1 节字段。

15.2 CallLedger

每个 inner call 至少保存：

- run/task/condition/repetition id；
- phase、role、model、provider；
- timestamps 与 latency；
- prompt/version/hash；

- usage/cost;
- response artifact/hash;
- retry/repair attempt;
- success/error/filter;
- parent call 与 candidate/claim ids。

15.3 mmd.trace.v2

统一 main 与 LiteLLM 分支：

- proposals、critiques、revisions;
- normalize mappings;
- ballots/classifications;
- final claim coverage;
- call ledger references;
- cost、timing、quorum、failures;
- protocol/prompt/model versions。

15.4 Parity requirement

D11 – 主实验 backend (已确认)

主实验优先使用 `litellm-integration`。若 backend parity gate 未通过，Stage 1–3 必须统一使用一个通过验证的 backend，不混合两个实现的数据。

G0 – Backend parity gate

在真实 benchmark 前，main 与 LiteLLM 对同一 deterministic mock fixture 必须产生语义等价的：

- phase path;
- candidate/source mappings;
- ballots/classifications;
- failure/quorum semantics;
- usage aggregation。

如果不能通过，正式实验只选择一个 backend，另一分支不混入数据。

15.5 Artifact 与合规

D12 – 公开资产范围 (已委托)

由 WP4 Dataset/scorer/quality 团队负责制定逐 benchmark、逐 artifact 的发布矩阵，WP6 复核。方案须在 G2 前说明题目、模型输出、trace、manifest、汇总结果和统计代码分别能否公开、需要何种脱敏，以及适用的 dataset license 与 provider 条款。未完成该审查的资产不得承诺公开。

- 原始 benchmark 题目是否可公开由 license 决定；

- API secrets 永不进入 trace;
 - 可能含个人/敏感信息的开放 prompt 不进入公开数据;
 - 发布 sanitized manifest、condition-level result、统计代码和必要的 claim trace;
 - 对无法公开的原始输出提供 hash、schema 和可复跑说明。
-

16. 阶段门槛

Go: Infrastructure Gate

- manifest 可重复启动/恢复;
- ledger 覆盖所有 inner calls;
- 成本总和可从 ledger 重建;
- 固定 mock parity 通过;
- 失败、retry、repair 都可见。

G1: 20-task Dry Run Gate

- 所有核心 conditions 均可完成;
- scorer 可重现;
- 无 system prompt/答案解析明显错误;
- 成本与延迟没有超出硬上限;
- 失败没有被静默丢弃。

G2: Screening/Pilot Gate

- 模型池有足够能力差异和错误互补性;
- 可以找到至少一组 ability/cost 大致匹配的高/低多样性 panel;
- 估计 task-level variance、失败率和平均成本;
- WP1/WP5 提交、团队批准 D8 最小有意义效应、ICER 规则与 D9 confirmatory 预算上限;
- 冻结 primary contrasts、任务和统计计划。
- WP4 提交、WP6 复核 D12 公开资产与合规矩阵。

G3: Data Lock Gate

- confirmatory manifest 不再改动;
- 排除项由盲于 condition 的流程决定;
- 结果表由独立成员从 raw ledger 重建;
- 主分析脚本在揭盲前固定。

G4: Claim Gate

- 论文主张不超过第 2.3 节允许层级；
- 负结果、失败率和 unknown cost 不隐藏；
- 至少一次独立复跑；
- 所有主图能追溯到 immutable artifact。

17. 可量化工作包与动态责任配置

本研究不预设团队人数。每个 work package 在启动时指定一名 accountable owner、零至多名 executor 和至少一名 reviewer；同一成员可以负责多个不冲突的工作包，也可以根据实际容量拆分执行任务。工作量以可验收产物和实验单元计量，不以固定人头或工期计量。

17.1 工作量符号

符号	含义	当前约束
(M)	screening 模型数	6–8
(T_s)	screening tasks	工程起点 120
(R_s)	每模型 screening repetitions	2
(T_c)	confirmatory tasks	G2 power simulation 决定
(R_c)	confirmatory repetitions	默认至少 3，G2 决定最终值
(K_c)	锁定的 condition × panel cells	G2 manifest 决定

因此，基础 screening 工作量为 $(N_s=M \times T_s \times R_s)$ ，按当前范围约为 1,440–1,920 个 solo runs；confirmatory 工作量为 $(N_c=T_c \times R_c \times K_c)$ 个 condition-runs。每个 condition-run 的 inner-call、token、成本和延迟乘数由 dry run 实测，不用静态调用数替代。

17.2 Work packages

WP	责任范围	量化待完成内容	完成标准	主要依赖
WP1	Protocol/preregistration	1 份 protocol、1 份 analysis plan；覆盖 RQ1–RQ7、H1–H3、13 项 D 决策及全部 primary estimands	D8/D9 获批；RQ/H、outcome、exclusion、multiplicity 一一映射	vo.3 study plan、Stage 0 pilot
WP2	Runner/manifest/ledger/trace	1 套 manifest schema、1 套 CallLedger、1 套 trace v2、1 套 resume/export pipeline、至少 1 个 deterministic parity fixture	Co–C6 均可从 manifest 启动；100% inner calls 可追踪；成本可从 ledger 重建	protocol fields、backend contract
WP3	Provider/backend/cost	(M=6\text{-}8) 个冻结模型的兼容矩阵；每个模型至少验证 structured output、usage、cost、timeout/retry 和 route metadata	所有入选模型通过调用契约；dry-run cost reconstruction 无未解释差额；backend gate 通过	WP2 schema、可用 API access
WP4	Dataset/scorer/quality	至少 2 个 primary adapters (R、K)、1 个 secondary adapter (I)；20-task dry-run set、约 120-task screening frame、scorer tests、data card、D12 发布矩阵	scorer 可重复；sampling frame 互斥且 hash 固定；license/provider 条款逐项记录	WP1 inclusion rules、dataset access
WP5	Screening/diversity/panel lock	验收 WP7 产生的 (N_s) 个 screening run 终态；1 份 ability/cost/error-correlation matrix；锁定 P-diverse、P-family 及各自 matched P-homo reference；1 份 power/cost simulation	screening 覆盖率与缺失规则通过；matching balance 达标或撤回 H1；panel selection 只使用 screening split；D8/D9 提案完成	WP3 model matrix、WP4 screening frame、WP7 screening batches

WP	责任范围	量化待完成内容	完成标准	主要依赖
WP6	Independent QA/reproduction/release	从 raw ledger 独立重建 100% primary tables; 至少 1 个锁定 batch 独立复跑; 人工 trace audit 基线为 ($\max(30, 5 \times N_c)$) 个随机 runs; 1 份 QA report 和 release checklist	G3/G4 通过; 所有主图可追溯; 差异有书面处置	WP2 artifacts、WP7 batches、WP8 analysis
WP7	Experiment execution	完成 20-task $\times$ Co-C6 dry run; 执行全部 (N_s) screening 与 (N_c) confirmatory units; 维护 immutable batch registry 和 drift anchors	计划单元均有 success/failure 终态; 无静默缺失; 所有 rerun 有原因码	WP2-WP5、Go-G2
WP8	Statistical analysis/paper	RQ1 的 5 个预定义增量、H1 difference-in-differences、H2 moderation、H3 paired transition; 质量/成本/延迟/Pareto/失败分析; 1 份主稿和 artifact index	主分析脚本在揭盲前冻结; 结果同时含 effect size、CI、负结果和敏感性分析	G2 analysis plan、WP7 data、WP6 rebuild

Stage 4 的角色消融、开放研究和外部系统比较单独建立 optional backlog，不计入 Paper A 最小完成量。

17.3 动态分工规则

- 每个 WP 必须有 accountable owner; executor 数量按当前容量增减。
- reviewer 不得审核自己生成的同一交付物; 一个人团队无法满足的独立复核必须在 G3/G4 前补充外部 reviewer。
- 运行主结果的人不能单独决定题目排除、失败重分类或异常 batch 删除。
- WP1/WP5、WP4/WP6 的既定决策关系保持不变，但不要求由不同的固定编号成员长期承担。
- 分工表在每个 gate 重新填写 owner、executor、reviewer 和剩余工作单元; 人员变化不改变已经锁定的 protocol、manifest 或统计计划。
- 增加成员优先并行化 adapters、provider validation、独立 batch 和 QA; 不得通过跳过 gate 或减少独立复核来压缩周期。

18. 依赖式里程碑与容量规划

研究周期由 gate、剩余工作单元和团队实际吞吐量决定，不在研究方案中预设周数。

18.1 关键路径

Milestone	必须完成的量化内容	Exit/Gate	可并行工作
Mo: Decision lock	D1–D13 均已确认或指定 owner/gate	v0.3	WP1 protocol skeleton、WP2/WP4 design
M1: Research-ready infrastructure	WP2 五类基础组件；WP3 模型契约；WP4 scorer skeleton	Go	provider validation、dataset adapters、analysis skeleton
M2: Dry run	20 tasks × Co–C6；全部 run 有终态和 ledger	G1	D12 合规矩阵、screening batch preparation
M3: Screening complete	(N_s=1,440\text{-}1,920) solo runs；ability/cost/error matrix	panel candidate set	analysis code、confirmatory manifest template
M4: Pilot/design lock	matched panels、(\delta_Q)、ICER、(T_c)、(R_c)、(K_c)、预算和 preregistration 全部锁定	G2	batch scheduling、QA sampling plan
M5: Confirmatory complete	(N_c=T_c\times R_c\times K_c) condition-runs 全部达到终态	raw data lock	独立 batch audit、Stage 4 go/no-go preparation
M6: Independent rebuild	100% primary tables 重建；人工 audit 与至少 1 个 batch 独立复跑完成	G3	paper methods、data card、artifact packaging
M7: Claim/release	主稿、QA report、artifact index、release checklist 完成	G4	可选 Stage 4

关键路径为 Mo→M1→M2→M3→M4→M5→M6→M7。Stage 4 不在关键路径上，不得阻塞 Paper A 的主结果与投稿。

18.2 根据团队规模动态估算周期

每次 gate 后更新以下容量表，而不是使用固定周计划：

Workstream	剩余单位	实测有效吞吐量	预计完成时间
Provider validation	未通过验证的 models	validated models / 工作日	剩余 models ÷ 吞吐量
Dataset/scorer	未通过验收的 adapters/tasks	validated adapters 或 tasks / 工作日	剩余单位 ÷ 吞吐量
Screening	剩余 solo runs	valid runs / 工作日	剩余 runs ÷ 吞吐量
Confirmatory	剩余 condition-runs	valid condition-runs / 工作日	剩余 runs ÷ 吞吐量
QA	剩余 batches/audit runs	validated units / 工作日	剩余单位 ÷ 吞吐量

总体完成时间取关键路径上各串行 milestone 的预计时间之和；同一 milestone 内取并行 workstream 中最慢者。吞吐量只使用 dry run 或已完成 batch 的有效结果估计，并计入失败、限流、人工审查和返工，不能用理论 API 并发上限代替。

19. 预算框架

19.1 不在当前版本填写固定总额

真实预算取决于模型池、reasoning tokens、输出长度、失败和 provider 价格。当前只定义预算过程：

1. Dry run 得到单 condition 的实际成本区间；
2. Screening 得到每模型每任务成本分布；
3. Pilot 根据效应方差模拟 confirmatory 条件数和重复数；
4. 预留 retry/failure、judge 和独立复跑预算；
5. 所有 batch 有全局和 per-run hard cap。

19.2 预算模板

可从以下比例开始，再由 pilot 修改：

- 10% infrastructure/dry run；
- 15% screening/pilot；
- 50% Stage 1–3 confirmatory；
- 10% robustness/role ablation；
- 10% Stage 4 外部效度、judge 与 human calibration；
- 5% independent rerun。

D9 – 总预算上限（决策流程已确认）

WP1 与 WP5 在 Stage 0 screening/pilot 后，根据实际 usage、失败率、效应方差和所需重复次数

提出 confirmatory 总预算及 contingency，团队在 G2 批准。没有已批准的预算上限，不启动 confirmatory。

20. 团队逐项决策清单

ID	决策	推荐默认	状态
D1	标题与主叙事	“Where do multi-model gains come from?”	☑ 已确认
D2	Paper A Stage 1–3 是否 tools off	是	☑ 已确认
D3	Primary task blocks	Reasoning + Knowledge；Instruction secondary	☑ 已确认
D4	模型池冻结规则	Stage o screening 前冻结；替换须重跑受影响 screening	☑ 已确认
D5	两个 primary confirmatory effects	diversity difference-in-differences、C6–C5	☑ 已确认
D6	角色消融是否进入主实验	否，数据锁定后条件性扩展	☑ 已确认
D7	是否运行外部系统对照	可选 Stage 4；非投稿必要条件	☑ 已确认
D8	最小有意义效应与 ICER	WP1/WP5 提案，G2 团队批准	🔄 流程已确认
D9	confirmatory 总预算上限	WP1/WP5 提案，G2 团队批准	🔄 流程已确认
D10	panel size	主实验固定 N=3	☑ 已确认
D11	主实验 backend	LiteLLM 优先；parity 失败则单 backend	☑ 已确认
D12	公开资产范围	WP4 制定发布矩阵，WP6 复核	🔄 已委托，G2 前完成
D13	目标 venue/截稿节奏	Stage o pilot 后决定	🔄 流程已确认

21. 可能结果与对应论文

主要结果	论文中心结论	后续方向
异构 panel + 结构化审议形成新 Pareto 前沿	有效多样性和审议都贡献	Paper B 学习触发与选模
异构 panel 有益、结构化审议不优于 vote	diversity 有价值，discussion 不划算	轻量 vote/quick router
结构化审议只在高分歧/知识任务有益	审议是条件性 test-time compute	Paper B selective deliberation
平均质量无增益但 disagreement 预测错误	trace 的价值在风险识别	Paper C calibration/escalation
所有收益均由 coordinator/额外 token 解释	当前实现不支持审议机制具有独立优势	将 MMD 定位为审计与实验工具
结果不稳定且依赖模型版本	组合规律高度非平稳	研究 model drift/online selection

失败标准不是“没有显著提升”，而是无法区分原因、无法复现或隐藏成本。清晰的负结果仍可形成有效论文。

22. 关键来源

- Du et al., *Improving Factuality and Reasoning in Language Models through Multiagent Debate*, ICML 2024: <https://proceedings.mlr.press/v235/du24e.html>
- Choi et al., *Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models?*, NeurIPS 2025: https://proceedings.neurips.cc/paper_files/paper/2025/file/934252acd87f254d5d4672fbd_e283bd2-Paper-Conference.pdf
- Kaesberg et al., *Voting or Consensus? Decision-Making in Multi-Agent Debate*, Findings ACL 2025: <https://aclanthology.org/2025.findings-acl.606/>
- Jiang et al., *LLM-Blender*, ACL 2023: <https://aclanthology.org/2023.acl-long.792/>
- Wang et al., *Mixture-of-Agents Enhances Large Language Model Capabilities*, 2024: <https://arxiv.org/abs/2406.04692>
- Fan et al., *iMAD*, AAI 2026: <https://ojs.aaai.org/index.php/AAAI/article/view/40181>
- Zhu et al., *Demystifying Multi-Agent Debate: The Role of Confidence and Diversity*, Findings ACL 2026: <https://aclanthology.org/2026.findings-acl.1694/>
- DRACO benchmark, 2026: <https://arxiv.org/abs/2602.11685>
- 本研究的完整来源台账: `research/mmd-research-plan/sources.md`

23. v0.4 状态与下一步

D1、D2、D3、D4、D5、D6、D7、D10 和 D11 已确认；D8、D9、D12 和 D13 已明确 owner、gate 与决策时点。v0.4 在此基础上取消固定团队人数和固定周计划，改用可量化 work packages、gate 依赖和实测吞吐量进行动态资源规划。

进入可提交的 preregistration draft 前仍须：

- 增加具体数据集版本、互斥 sampling frame 与 dataset hash；
- 冻结候选模型、provider route 和 price snapshot；
- 由 WP1/WP5 完成 D8/D9，并记录 G2 批准结果；
- 由 WP4 完成、WP6 复核 D12 发布矩阵；
- 增加实验条件 $\times$ task $\times$ panel $\times$ repetition 的调用量和预算估算；
- 将本方案转换为正式 protocol 与 analysis plan；
- 拆解 WP1–WP8 的代码 issue/backlog；
- 在 Stage 0 pilot 后确认 D13 venue 与截稿节奏。